Introduction au Machine Learning

Laure Delisle
19 février 2020

Background

Laure Delisle - Research engineer

- … *sabbatical*
- Element AI
- Lastline
- CEA
- Airbus defence

⋮

- NDH Kids

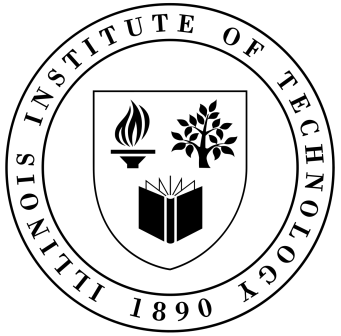

Machine Learning 101 - plan

Machine learning
- définition
- ML vs Intelligence Artificielle / Deep Learning / Data Science
- taxonomie

Process, données, vocabulaire
- données, data preparation
- training
- mesure de performance

En pratique
- dataset NSL-KDD (classification, clustering)

Objectifs pédagogiques

```
Machine learning
    ├ Définition, taxonomie
    ├ Algorithmes
    ├ Techniques
    └ Mise en application
```

Machine Learning (apprentissage machine)

Ensemble de techniques, reposant sur des **statistiques** et **algorithmes,** par lesquelles un **programme** informatique est capable d'**apprendre par expérience** à réaliser un ensemble de **tâches** sous contrainte d'une **mesure de performance**.

Offset(h)	00	01	02	03	04	05	06	07	08	09	0A	0B	0C	0D	0E	0F
00000000	4D	5A	90	00	03	00	00	00	04	00	00	00	FF	FF	00	00
00000010	B8	00	00	00	00	00	00	00	40	00	00	00	00	00	00	00
00000020	00	00	00	00	00	00	00	00	00	00	00	00	00	00	00	00
00000030	00	00	00	00	00	00	00	00	00	00	00	00	80	00	00	00
00000040	0E	1F	BA	0E	00	B4	09	CD	21	B8	01	4C	CD	21	54	68
00000050	69	73	20	70	72	6F	67	72	61	6D	20	63	61	6E	6E	6F
00000060	74	20	62	65	20	72	75	6E	20	69	6E	20	44	4F	53	20
00000070	6D	6F	64	65	2E	0D	0D	0A	24	00	00	00	00	00	00	00
00000080	50	45	00	00	4C	01	03	00	8D	FA	81	4D	00	00	00	00
00000090	00	00	00	00	E0	00	02	01	0B	01	08	00	00	0A	00	00
000000A0	00	08	00	00	00	00	00	00	9E	28	00	00	00	20	00	00
000000B0	00	40	00	00	00	00	40	00	00	20	00	00	00	02	00	00
000000C0	04	00	00	00	00	00	00	00	04	00	00	00	00	00	00	00
000000D0	00	80	00	00	00	02	00	00	01	82	00	00	03	00	40	85
000000E0	00	00	10	00	00	10	00	00	00	00	00	10	00	00	10	00
000000F0	00	00	00	00	10	00	00	00	00	00	00	00	00	00	00	00

$$S(x) = \frac{1}{1 + e^{-x}}$$

AI, DL, DS ?

`Intelligence artificielle`

└ Système capable de réaliser des tâches qui nécessite normalement une intelligence organique (prise de décision, perception visuelle, compréhension du langage…). [1]

`Deep Learning`

└ Sous-famille du Machine Learning, regroupant des algorithmes de **réseaux de neurones**, inspirés de la structure neuronale du cerveau.

`Data Science`

└ Ensemble de techniques pour **préparer, visualiser, analyser des données** pour en extraire des informations ou prendre des décisions.

[1] From the Oxford Dictionary

Interconnexion - ML, AI, DL, DS

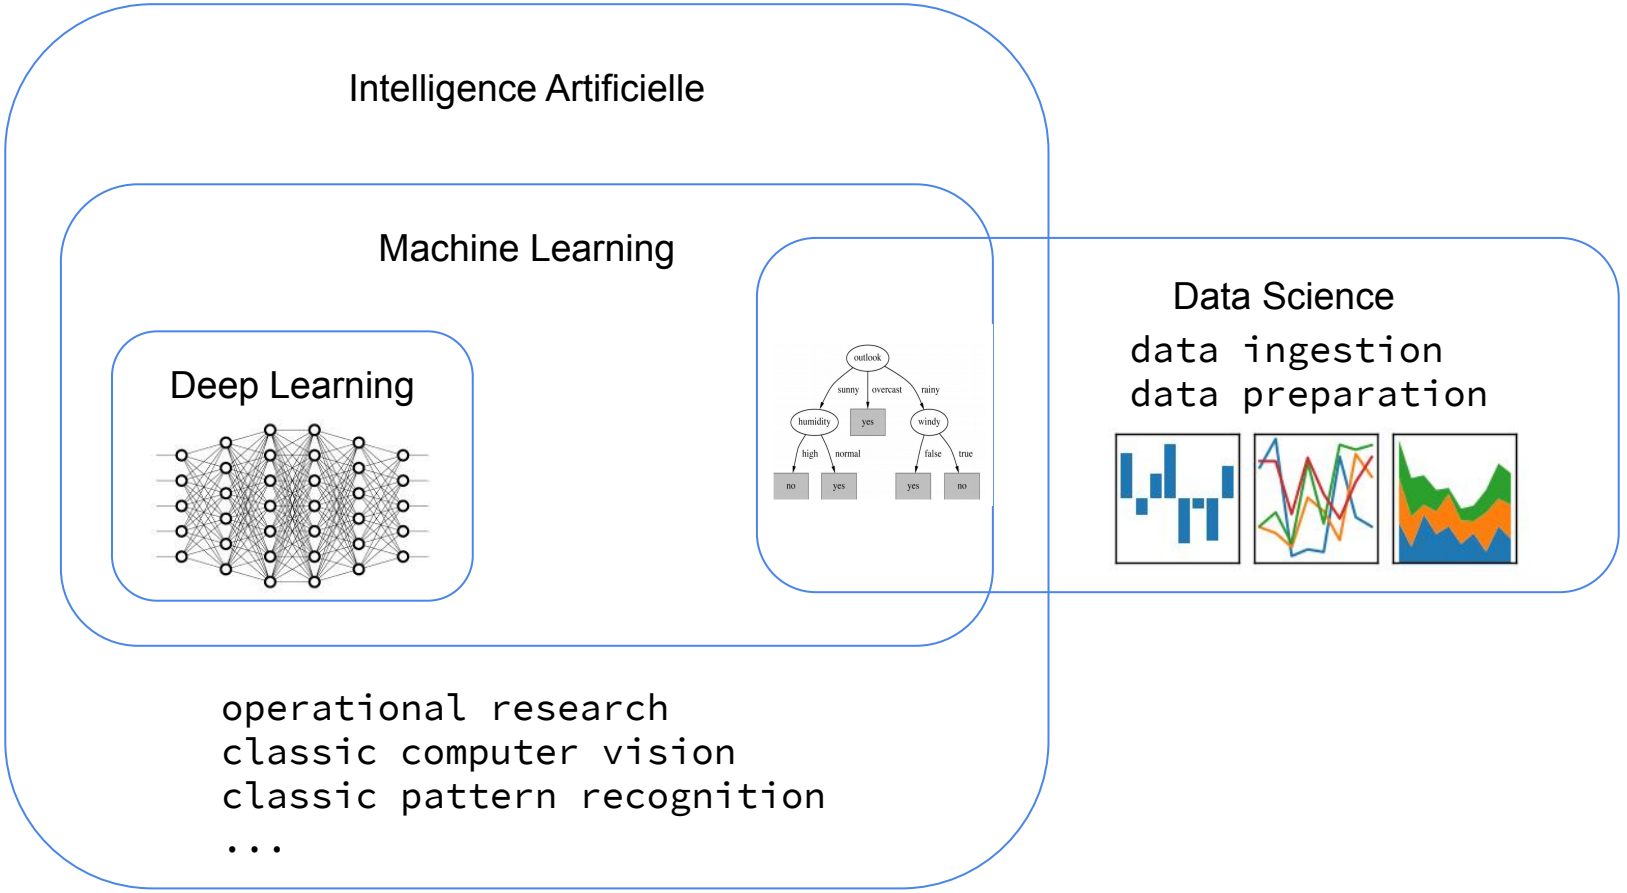

Taxonomie - Machine Learning

Apprentissage supervisé
- ├ données **‘labellées’** (étiquetées)
- ├ régression
- └ classification

var 1	...	var n	target
‘blanc’	...	83.2	A
‘vert’	...	47.5	B
‘blanc’	**...**	**75.7**	**?**

Apprentissage non supervisé
- ├ données **non ‘labellées’**
- └ clustering

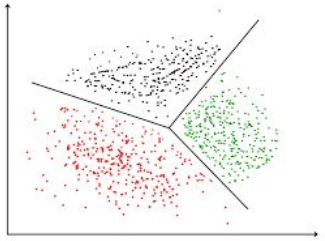

Apprentissage par renforcement
- ├ environnement + actions + **récompenses + agent autonome**
- ├ end-to-end
- ├ inverse
- └ par démonstration

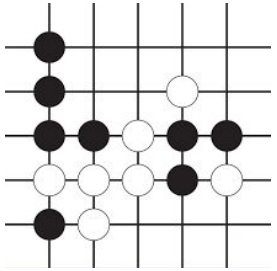

Catalystes et limites

```
Historique
├ régression: 1805 (Legendre), 1809 (Gauss)
├ classification: 1955 (KMeans)
├ clustering: 1990's (Kernel machines, Graphical models)
└ deep learning: 1958 (Perceptron), 1986 (Backpropagation)

Catalystes
├ plus de données, dataset plus larges
├ modèles plus complexes
└ puissance de calcul (CPU, GPU, TPU)

Limites
├ données adéquates et préparées
├ overfitting
├ connaissance du domaine
└ déploiement en production
```

Process, méthodes, vocabulaire

- Données
  - types
  - manquantes
  - déséquilibrées
  - aberrantes
- Variables
  - sélection (filtre, wrapper, embedded)
  - engineering
  - réduction de dimension
- Phases
  - training
  - validation
  - testing

Process, méthodes, vocabulaire

```
Training
    ├ loss
    ├ descente de gradient
    ├ vanishing/exploding gradient
    └ optimization

Validation / testing
    ├ cross-validation, validation/test, out-of-time
    ├ mesures de performance
    ├ compromis variance/biais
    └ overfitting, underfitting
```

Données - types

```
Tabulaires
├ numériques
├ catégoriques
└ ordinales

Séquentielles
├ temporelles
└ texte
```

Données manquantes (missing)

Pourquoi ?
- au hasard
- conditionnellement à une autre variable

Stratégie
- suppression (col, observation)
- 'imputation' : interpolation

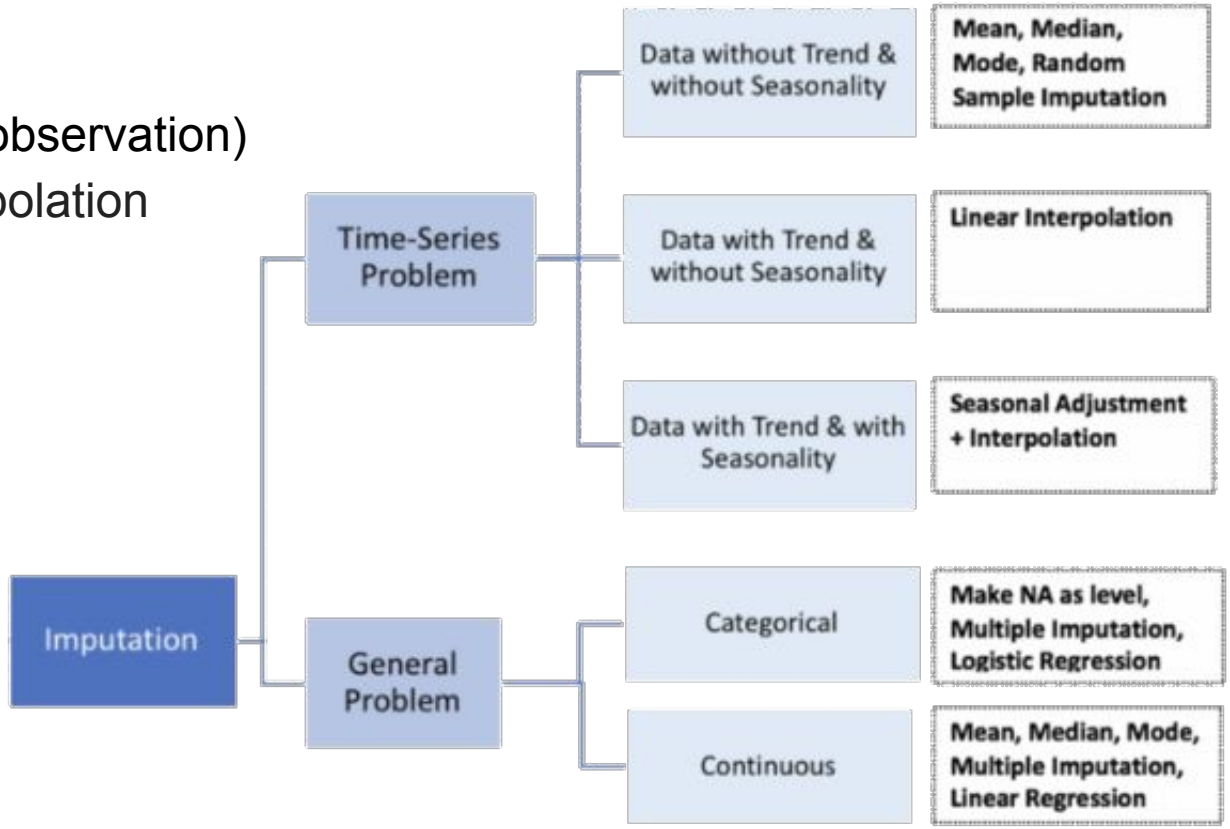

Données aberrantes (outliers)

```
Pourquoi ?
    ├ au hasard
    ├ erreur de mesure
    └ conditionnellement à une autre variable

Stratégie
    ├ suppression (col, observation)
    └ choix d'une méthode plus robuste
```

Données déséquilibrées (unbalanced)

Biais
- sous-représentation
- le modèle apprend davantage depuis la classe majoritaire

Stratégie
- up-sampling la classe minoritaire
- down-sampling la classe majoritaire
- collecter davantage de données, changer de dataset

Risk
- study by Joy Buolamwini, M.I.T. [1]

[1] https://www.nytimes.com/2018/02/09/technology/facial-recognition-race-artificial-intelligence.html

Training, testing

Apprentissage
- calcul d'erreur
- ajustement par descente du gradient

Test - mesure de performance
- données non utilisées pour l'apprentissage
- matrice de confusion (accuracy/precision/recall/F1)
- SSE, R^2

Validation
- 3eme jeu de données
- pour ajuster des hyperparamètres

Risques
- overfitting, underfitting
- exploding gradient

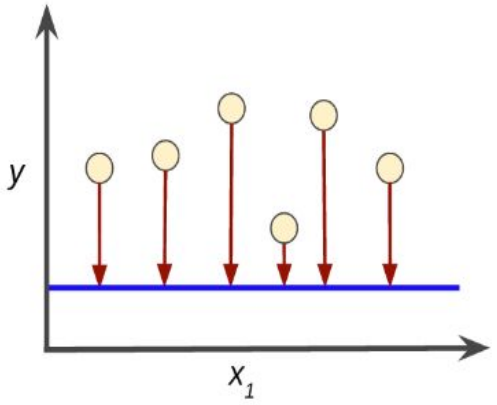

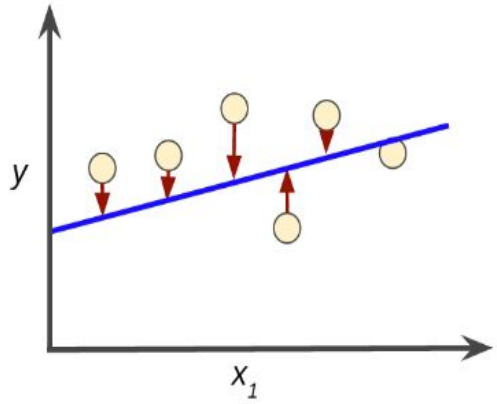

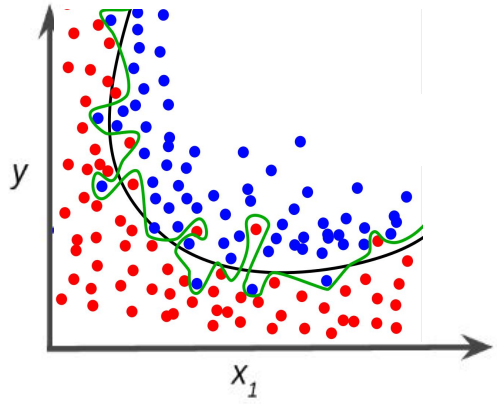

Régression

Contexte
- données labellées (apprentissage **supervisé**)
- label **numérique**

Modèle
- $Y = f(\mathbf{X}, \boldsymbol{\beta})$
- **X** : variables
- **β** : paramètres du modèles
- Y : variables

Mesure de performance
- SSE, R^2

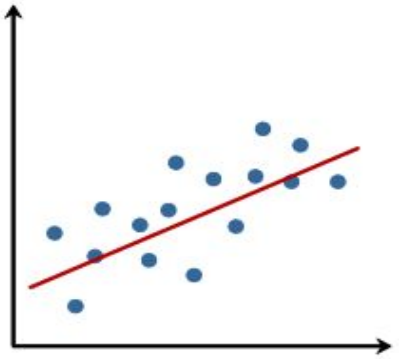

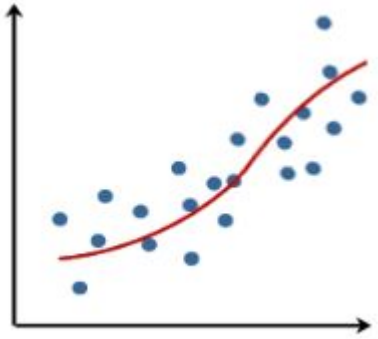

Classification

`Contexte`
- données labellées (apprentissage **supervisé**)
- label **catégorique**

`Modèles`
- régression logistique, Naive Bayes
- arbres de décision, random forest
- réseaux de neurones

`Mesure de performance`
- matrice de confusion
- accuracy, precision, recall, F1

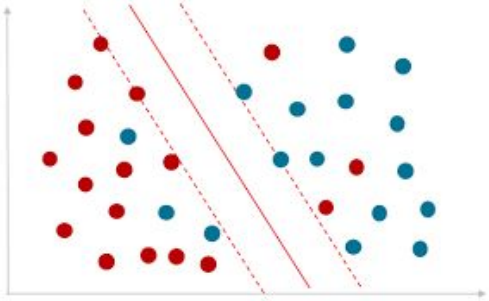

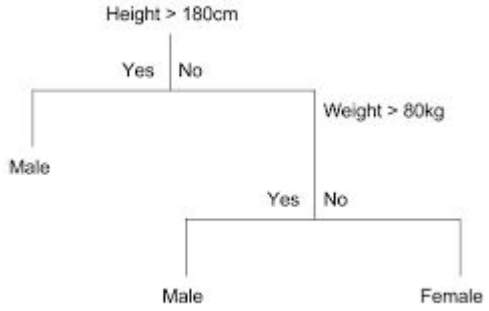

TP - classification

`Objectifs`

- load le dataset NSL-KDD (intrusion detection)
- préparation des données
- train / test split
- fit du modèle
- prédiction et évaluation

`Méthodes mise en oeuvre`

- type de ML : supervisé > classification
- algorithme : Decision Tree / XGBoost
- techniques : one-hot encoding, standardization
- metric : confusion matrix

`Dataset`

- https://plg.uwaterloo.ca/~gvcormac/treccorpus07/

Clustering

Contexte
- données non labellées (apprentissage **non-supervisé**)
- label **catégorique**

Modèles
- kNN, k-means
- hiérarchique, locally sensitive hashing
- density-based

Mesure de performance
- homogénéité, completeness
- silhouette
- critère de variance ratio (Calinski-Harabaz)

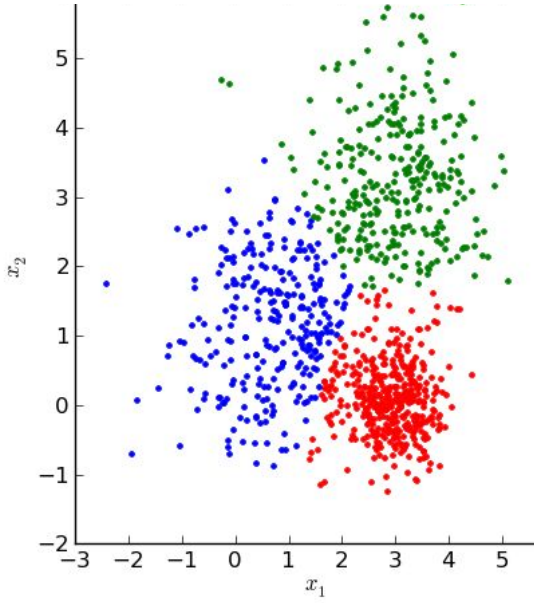

TP - clustering

`Objectifs`

- load le dataset NSL-KDD (intrusion detection)
- préparation des données
- expérimentation avec différents modèles
- évaluation de la qualité des clusters

`Méthodes mise en oeuvre`

- type de ML : non-supervisé > clustering
- algorithme : K-means, DBSCAN
- metric : silhouette, homogénéité

General resources

Datasets

- http://archive.ics.uci.edu/ml/index.php (many open datasets to practice)

Apprentissage par renforcement

- http://incompleteideas.net/book/RLbook2018.pdf (bible du domaine)

Deep Learning

- https://www.deeplearningbook.org/ (bible, un peu datée (2016))

Pour aller plus loin

- https://www.udacity.com/course/deep-learning-pytorch--ud188 (pytorch)

Régression (2)

Hypothèses

- Y est une variable continue
- les variables X sont linéairement indépendantes
- les observations sont indépendantes (erreurs non corrélées)

Régression linéaire

- polynome (2D) $Y = \beta_0 + \beta_1 x + \beta_2 x^2 + \ldots + \beta_n x^n$
- multivariate $Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \ldots + \beta_n x_n = \mathbf{\beta x}$ (with $x_0 = 1$)